

MINI PROJECT I

DATA PREPROCESSING : CAFFE SALES

INTRODUCTION

EDUCATION:

UNIVERSITAS DIPONEGORO(2021-2025) - SI INFORMATIKA
BANGKIT ACADEMY - MACHINE LEARNING COHORT (2024)
DIBIMBING - DATA ANALYTICS (2026)

EXPERIENCES:

- 1.ASISTEN PRAKTIKUM MATAKULIAH OOP DAN MACHINE LEARNING
- 2.ML PROJECT AT PT PERTAMINA HULU ROKAN
- 3.TEAM PROJECT MOBILE APP APPLICATION "JOURNEY ON SOLO"



[HTTPS://MEDIUM.COM/@ARYACHENKO46](https://medium.com/@aryachenko46)



[ARYASHEV-PHI-RUST.VERCEL.APP](https://aryashev-phi-rust.vercel.app)



[LINKEDIN.COM/IN/ARYADHEFFANS46](https://linkedin.com/in/aryadheffans46)

ARYA DHEFFAN SHEVCHENKO




PROJECT OVERVIEW


Sistem Informasi Berbasis Web dengan Fitur Inferred Prediction

Dashboard yang berisi informasi sumur-sumur yang berlokasi di wilayah rokan, baik dari spesifikasinya bahkan total penghasilan minyaknya

Web ini juga menyediakan fitur ML/AI yang dapat memprediksi total penghasilan barrel minyak cukup degan melampirkan csv atau mengisi form



Tools




PROJECT OVERVIEW

Mobile Application “Journey On Solo”

Mobile app yang menyediakan fitur rekomendasi untuk new user berdasarkan preferences/ketertarikan dari user itu sendiri

Tools





PROJECT OVERVIEW

Klasifikasi Video Asli Vs AI Menggunakan
Model Generative Adversarial Network


Projek ML/AI membuat prediksi atau klasifikasi video yang dilampirkan user, apakah videonya asli rekaman atau generate hasil AI

Tools:






DATA EXPLORATION



Apa yang akan dibahas?



ABOUT DATASETS

Column Name	Description	Data Type
Transaction ID	Nilai unik tiap transaksi	Text (str)
Item	Makanan/minum yang dipesan	Text(str)
Quantity	Jumlah pesanan	Numeric
Price Per Unit	Harga per makanan/minuman	Numeric
Total Spent	Quantity dikali Price Per Unit	Numeric
Payment Method	Metode pembayaran	Text(str)
Location	Tipe pemesanan (makan di tempat/dibawa pulang)	Text(str)
Transaction Date	Tanggal pemesanan	Datetime

NOTE: SEMUA KOLOM MEMILIKI TIPE DATA "OBJECT" DI KONDISI AWAL


Sumber Data	Kaggle
Size	10000 x 8

IMPORT DATA

LIBRARY : PANDAS, NUMPY, MATPLOTLIB, SKLEARN.PREPROCESSING
 JENIS FILE DATASET : .CSV
 EDITOR: VISUAL STUDIO CODE (NOTEBOOK)

	Transaction ID	Item	Quantity	Price Per Unit	Total Spent	Payment Method	Location	Transaction Date
0	TXN_1961373	Coffee	2	2.0	4.0	Credit Card	Takeaway	2023-09-08
1	TXN_4977031	Cake	4	3.0	12.0	Cash	In-store	2023-05-16
2	TXN_4271903	Cookie	4	1.0	ERROR	Credit Card	In-store	2023-07-19
3	TXN_7034554	Salad	2	5.0	10.0	UNKNOWN	UNKNOWN	2023-04-27
4	TXN_3160411	Coffee	2	2.0	4.0	Digital Wallet	In-store	2023-06-11
...	...	...	...	...	...	...	...	...
9995	TXN_7672686	Coffee	2	2.0	4.0	NaN	UNKNOWN	2023-08-30
9996	TXN_9659401	NaN	3	NaN	3.0	Digital Wallet	NaN	2023-06-02
9997	TXN_5255387	Coffee	4	2.0	8.0	Digital Wallet	NaN	2023-03-02
9998	TXN_7695629	Cookie	3	NaN	3.0	Digital Wallet	NaN	2023-12-02
9999	TXN_6170729	Sandwich	3	4.0	12.0	Cash	In-store	2023-11-07

10000 rows × 8 columns



Jumlah null value pada setiap kolom:

```
Transaction ID      0
Item                333
Quantity            479
Price Per Unit      533
Total Spent         502
Payment Method      2579
Location            3265
Transaction Date     460
```

← Cek Null Value

DATASET SECARA UMUM

	Transaction ID	Item	Quantity	Price Per Unit	Total Spent	Payment Method	Location	Transaction Date
count	10000	9667	9862	9821	9827	7421	6735	9841
unique	10000	10	7	8	19	5	4	367
top	TXN_6170729	Juice	5	3.0	6.0	Digital Wallet	Takeaway	UNKNOWN
freq	1	1171	2013	2429	979	2291	3022	159

Pemahaman awal:

- Kebanyakan kolom mempunyai nilai unik
- Semua tanggal dalam 1 tahun mempunyai nilai
- Bisa dilihat kolom selain transaction id mempunyai nilai null

ANALISA KOLOM(CATEGORICAL)

Jumlah tiap item:

Item	
Juice	1171
Coffee	1165
Salad	1148
Cake	1139
Sandwich	1131
Smoothie	1096
Cookie	1092
Tea	1089
UNKNOWN	344
ERROR	292

Jumlah tiap 'Quantity':

Quantity	
----------	--

5	2013
2	1974
4	1863
3	1849
1	1822
UNKNOWN	171
ERROR	170

Jumlah tiap 'Location':

Location	
----------	--

Takeaway	3022
In-store	3017
ERROR	358
UNKNOWN	338

Jumlah tiap 'Payment Method':

Payment Method	
Digital Wallet	2291
Credit Card	2273
Cash	2258
ERROR	306
UNKNOWN	293

Jumlah tiap 'Price Per Unit':

Price Per Unit	
3.0	2429
4.0	2331
2.0	1227
5.0	1204
1.0	1143
1.5	1133
ERROR	190
UNKNOWN	164


Tahun transaksi: [2023. nan]

Jumlah Transaksi Tiap Bulan:

Transaction Date	
1.0	818
2.0	727
3.0	827
4.0	774
5.0	777
6.0	818
7.0	791
8.0	803
9.0	788
10.0	838
11.0	784
12.0	795

Pemahaman awal:

- Quantity dan Price Per Unit, walaupun mempunyai nilai numeric tapi mempunyai nilai yang seragam
- Nilai unknown dan error dari quantity dan price per unit bisa dicari jika salah satunya mempunyai nilai pasti
- Tahun transaksi hanya pada tahun 2023 dan tiap bulan, jumlah transaksinya hampir seragam
- Data sudah konsisten




Pemahaman awal:


- Berdasarkan histogram, semakin tinggi jumlah pembayaran semakin kecil frekuensi transaksinya



DATA CLEANING



Apa yang akan dibahas?



MENANGANI NULL, UNKNOWN, DAN ERROR

(QUANTITY, PRICE PER UNIT, DAN TOTAL SPENT)



QUANTITY X PRICE PER UNIT = TOTAL SPENT

↑
Pola sudah jelas

Nilai yang kosong dapat diisi jika 2 nilai yang lain mempunyai nilai



Untuk mengisi salah satu nilai, 2 nilai yang lain harus ada (tidak null)

LANGKAH AWAL



ITEM → PRICE PER UNIT

	Item	Price Per Unit	count
0	Cake	3.0	1085
1	Coffee	2.0	1108
2	Cookie	1.0	1026
3	Juice	3.0	1110
4	Salad	5.0	1082
5	Sandwich	4.0	1082
6	Smoothie	4.0	1036
7	Tea	1.5	1023

Tiap item punya harga yang pasti, tetapi ada item yang berbeda dengan harga yang sama seperti cake dan juice, sandwich dan smoothie

PENGISIAN PRICE PER UNIT

```
# Terlihat pola harga per item
# Dapat mengisi Price Per Unit yang Null
price_map = {
    'Coffee': 2.0,
    'Cake': 3.0,
    'Juice': 3.0,
    'Cookie': 1.0,
    'Sandwich': 4.0,
    'Smoothie': 4.0,
    'Tea': 1.5,
    'Salad': 5.0
}

mask = df['Price Per Unit'].isnull() | df['Price Per Unit'].isin(["ERROR", "UNKNOWN"])
df.loc[mask, 'Price Per Unit'] = df.loc[mask, 'Item'].map(price_map)
```

Dengan metode masking, nilai dapat diisi berdasarkan nama item

After

```
Jumlah null value
54
```

Tersisa untuk item yang bernilai unknown atau error

PENGISIAN PRICE PER UNIT

```
mask = (  
    df['Price Per Unit'].isnull() &  
    df['Quantity'].notna() &  
    df['Total Spent'].notna()  
)  
  
df.loc[mask, 'Price Per Unit'] = df.loc[mask, 'Total Spent'] / df.loc[mask, 'Quantity']
```

KEPUTUSAN TERAKHIR

Drop 6 kolom tadi karena tidak memberi insight untuk analisa lanjut

```
# Keputusan: DROP Price Per Unit yang masih null  
mask = (df['Price Per Unit'].isnull())  
# Masukkan ke df_drop untuk analisa lebih lanjut  
df_drop = df[mask]  
df = df[~mask]
```

After

```
Jumlah null value  
6
```

Tersisa untuk item yang bernilai unknown atau error dan quantity atau total spent yang bernilai kosong

PENGISIAN ITEM



Ada item yang berbeda dengan harga yang sama

```
# Isi Item, cukup yang pasti
item_map = {
    1.0: 'Cookie', 1.5: 'Tea',
    2.0: 'Coffee', 5.0: 'Salad'
}
```

```
mask = (df['Item'].isnull()) | (df["Item"] == "ERROR") | (df['Item'] == "UNKNOWN")
df.loc[mask, 'Item'] = df.loc[mask, 'Price Per Unit'].map(item_map)
```

Mulai dari yang pasti

Item null yang tersisa

Price	Per Unit
3.0	247
4.0	227

Langkah selanjutnya dapat dilakukan dengan probabilitas



PENGISIAN ITEM

```
# Keputusan: Isi dengan probabilitas
np.random.seed(42)

total_3 = 1085 + 1110
total_4 = 1082 + 1036

mask_3 = ((df['Item'].isnull()) | (df["Item"] == "ERROR") | (df['Item'] == "UNKNOWN")) & (df['Price Per Unit'] == 3.0)
mask_4 = ((df['Item'].isnull()) | (df["Item"] == "ERROR") | (df['Item'] == "UNKNOWN")) & (df['Price Per Unit'] == 4.0)

df.loc[mask_3, 'Item'] = np.random.choice(
    ['Cake', 'Juice'],
    size=mask_3.sum(),
    p=[1085/total_3, 1110/total_3]
)

df.loc[mask_4, 'Item'] = np.random.choice(
    ['Sandwich', 'Smoothie'],
    size=mask_4.sum(),
    p=[1082/total_4, 1036/total_4]
)
```

Menggunakan probabilitas untuk menjaga distribusi item tetap seimbang

PENGISIAN QUANTITY

```
# Isi Quantity dengan Total Spent dibagi Price Per Unit
mask = (
    df["Total Spent"].notna() &
    df["Quantity"].isnull()
)

df.loc[mask, "Quantity"] = df.loc[mask, "Total Spent"] / df.loc[mask, "Price Per Unit"]
```

Menggunakan metode masking dengan mengisi quantity dengan total spent dibagi price per unit

KEPUTUSAN AKHIR

```
# Keputusan: Drop
# Update df_drop (dataframe yang didrop) -> Penggunaannya untuk analisa lebih lanjut, misal untuk melihat pola missing value
df_drop = pd.concat([df_drop, df[df['Quantity'].isnull()]], ignore_index=True)
df.dropna(subset=['Quantity'], inplace=True)
```

20 baris (0,002% dari seluruh data) yang tidak mempunyai nilai quantity dan total spent tidak memberi insight untuk analisa lebih lanjut

After

```
Jumlah null value
20
```

Tersisa nilai yang quantity dan total spent bernilai null

PENGISIAN TOTAL SPENT


Karena quantity dan price per unit sudah dipastikan tidak ada yang null, total spent diisi dengan perkalian quantity dan price per unit

```
# Isi total spent yang null dengan quantity dikali price per unit
mask = (
    | df["Total Spent"].isnull()
)

df.loc[mask, "Total Spent"] = df.loc[mask, "Quantity"] * df.loc[mask, "Price Per Unit"]
```

```
Jumlah null value pada kolom 'Total Spent':
0
```

PENGISIAN PAYMENT METHOD



Payment Method	
Digital Wallet	2284
Credit Card	2268
Cash	2254
ERROR	305
UNKNOWN	293

Distribusi nilai seimbang, mengisi null, error, dan unknown dapat menggunakan probabilitas untuk menjaga keseimbangan distribusi.

```
# Isi Payment Method dengan probabilitas
np.random.seed(42)


total = 2284 + 2268 + 2254

mask = df['Payment Method'].isin(['ERROR', 'UNKNOWN']) | df['Payment Method'].isnull()


df.loc[mask, 'Payment Method'] = np.random.choice(
    ['Digital Wallet', 'Credit Card', 'Cash'],
    size=mask.sum(),
    p=[2284/total, 2268/total, 2254/total]
)
```

After

Payment Method	
Digital Wallet	3352
Credit Card	3322
Cash	3300



PENGISIAN LOCATION



Location	
Takeaway	3016
In-store	3006
ERROR	357
UNKNOWN	338

Mirip dengan kolom 'Payment Method', distribusi nilai seimbang, mengisi null, error, dan unknown dapat menggunakan probabilitas untuk menjaga keseimbangan distribusi.

After

Location	
Takeaway	4989
In-store	4985

```
np.random.seed(42)

total = 3016 + 3006

mask = df['Location'].isin(['ERROR', 'UNKNOWN']) | df['Location'].isnull()

df.loc[mask, 'Location'] = np.random.choice(
    ['Takeaway', 'In-store'],
    size=mask.sum(),
    p=[3016/total, 3006/total]
)
```



PENGISIAN TRANSACTION DATE


Jumlah null value pada setiap kolom:

Transaction ID	0
Item	0
Quantity	0
Price Per Unit	0
Total Spent	0
Payment Method	0
Location	0
Transaction Date	460

```
# Keputusan: Drop
# Masukkan ke df_drop untuk analisa lebih lanjut
df_drop = pd.concat([df_drop, df[mask['Transaction Date']]], ignore_index=True)
df.dropna(subset=['Transaction Date'], inplace=True)
```

Karena jumlah baris 460 data (0,046% dari seluruh data) tergolong sedikit, keputusan terakhir untuk menangani nilai null ini adalah dengan metode drop. Transaction date yang kosong tidak memberi insight tren mingguan atau bulanan

APAKAH ADA OUTLIER?



Batas kiri

-0.8

TOTAL SPENT

Batas kanan

24.0

APAKAH ADA OUTLIER?

Dataframe outlier



	Transaction ID	Item	Quantity	Price Per Unit	Total Spent	Payment Method	Location	Transaction Date
10	TXN_2548360	Salad	5.0	5.0	25.0	Cash	Takeaway	2023-11-07
51	TXN_6342161	Salad	5.0	5.0	25.0	Digital Wallet	Takeaway	2023-01-08
52	TXN_8914892	Salad	5.0	5.0	25.0	Digital Wallet	Takeaway	2023-03-15
96	TXN_5220895	Salad	5.0	5.0	25.0	Cash	In-store	2023-06-10
100	TXN_9517146	Salad	5.0	5.0	25.0	Cash	Takeaway	2023-10-30
...	...	...	...	...	...	...	...	...
9791	TXN_1232346	Salad	5.0	5.0	25.0	Digital Wallet	In-store	2023-01-04
9805	TXN_9506076	Salad	5.0	5.0	25.0	Digital Wallet	In-store	2023-01-17
9879	TXN_6393305	Salad	5.0	5.0	25.0	Digital Wallet	In-store	2023-10-19
9908	TXN_8922585	Salad	5.0	5.0	25.0	Credit Card	Takeaway	2023-06-22
9971	TXN_6120851	Salad	5.0	5.0	25.0	Cash	Takeaway	2023-02-04

259 rows × 8 columns


Dengan total 259 baris outlier mempunyai nilai yang sama (25).

Jika menggantikan nilai total spent dari 25 ke 24 justru menyesatkan.


“OUTLIER SECARA STATISTIK TAPI TIDAK OUTLIER SECARA BISNIS”



DATA MANIPULATION



Apa yang akan dibahas?



KONVERSI TIPE DATA

Transaction ID	object
Item	object
Quantity	object
Price Per Unit	object
Total Spent	object
Payment Method	object
Location	object
Transaction Date	object

```
df["Quantity"] = pd.to_numeric(df["Quantity"].str.strip(), errors = "coerce")
df["Price Per Unit"] = pd.to_numeric(df["Price Per Unit"].str.strip(), errors = "coerce")
df["Total Spent"] = pd.to_numeric(df["Total Spent"].str.strip(), errors = "coerce")
df["Transaction Date"] = pd.to_datetime(df["Transaction Date"].str.strip(), format="%Y-%m-%d", errors = "coerce")
```

Transaction ID	object
Item	object
Quantity	float64
Price Per Unit	float64
Total Spent	float64
Payment Method	object
Location	object
Transaction Date	datetime64[ns]

Data yang isinya numerik dan tanggal harus disesuaikan, yang sebelumnya bertipe objek diubah ke tipe data yang sesuai (float dan datetime)

FILTERING

Transaksi high value (di atas rata-rata)

```
# Transaksi high-value (Total Spent di atas rata-rata)
df.loc[df['Total Spent'] > df['Total Spent'].mean(),
       ['Item', 'Quantity', 'Price Per Unit', 'Total Spent']]
```

	Item	Quantity	Price Per Unit	Total Spent
1	Cake	4.0	3.0	12.0
3	Salad	2.0	5.0	10.0
5	Smoothie	5.0	4.0	20.0
6	Cake	3.0	3.0	9.0
7	Sandwich	4.0	4.0	16.0
...	...	...	...	...
9990	Coffee	5.0	2.0	10.0
9991	Sandwich	3.0	4.0	12.0
9992	Smoothie	4.0	4.0	16.0
9994	Smoothie	4.0	4.0	16.0
9999	Sandwich	3.0	4.0	12.0

4129 rows × 4 columns

Transaksi dengan quantity besar

```
# Transaksi quantity besar
df.loc[df['Quantity'] >= 4,
       ['Item', 'Quantity', 'Price Per Unit', 'Total Spent']]
```

	Item	Quantity	Price Per Unit	Total Spent
1	Cake	4.0	3.0	12.0
2	Cookie	4.0	1.0	4.0
5	Smoothie	5.0	4.0	20.0
7	Sandwich	4.0	4.0	16.0
8	Juice	5.0	3.0	15.0
...	...	...	...	...
9989	Juice	5.0	3.0	15.0
9990	Coffee	5.0	2.0	10.0
9992	Smoothie	4.0	4.0	16.0
9994	Smoothie	4.0	4.0	16.0
9997	Coffee	4.0	2.0	8.0

3847 rows × 4 columns

SORTING

Transaksi volume tinggi tapi revenue rendah

```
# Item paling murah, quantity terbanyak (volume tinggi tapi revenue rendah)
df.sort_values(['Price Per Unit', 'Quantity'], ascending=[True, False]).head(10)
```

	Transaction ID	Item	Quantity	Price Per Unit	Total Spent	Payment Method	Location	Transaction Date
13	TXN_9437049	Cookie	5.0	1.0	5.0	Digital Wallet	Takeaway	2023-06-01
26	TXN_5183041	Cookie	5.0	1.0	5.0	Credit Card	In-store	2023-04-20
87	TXN_3955361	Cookie	5.0	1.0	5.0	Cash	Takeaway	2023-04-02
89	TXN_4132730	Cookie	5.0	1.0	5.0	Cash	In-store	2023-03-12
108	TXN_4358673	Cookie	5.0	1.0	5.0	Digital Wallet	Takeaway	2023-12-28
226	TXN_6623508	Cookie	5.0	1.0	5.0	Digital Wallet	Takeaway	2023-05-18
394	TXN_8224079	Cookie	5.0	1.0	5.0	Cash	In-store	2023-10-16
418	TXN_1002457	Cookie	5.0	1.0	5.0	Digital Wallet	Takeaway	2023-09-29
475	TXN_2696664	Cookie	5.0	1.0	5.0	Digital Wallet	In-store	2023-01-07
503	TXN_3664656	Cookie	5.0	1.0	5.0	Credit Card	Takeaway	2023-08-13

PENGKATEGORIAN (GROUPBY)

Menu paling laku

Item	
Coffee	3766.0
Juice	3713.0
Salad	3644.0
Cake	3623.0
Sandwich	3578.0
Smoothie	3552.0
Tea	3441.0
Cookie	3427.0
Name: Total	Quantity

Pemahaman pertama:

- Kopi paling laku di cafe ini
- Walaupun salad lebih mahal dari cookie, salad lebih laku

Jumlah transaksi tiap metode pembayaran

Payment Method	
Digital Wallet	28547.0
Cash	28320.0
Credit Card	28001.5

Pemahaman pertama:

- Jumlah transaksi antar metode pembayaran seimbang

FEATURE ENGINEERING

```
df["Month"] = df["Transaction Date"].dt.month
```

```
df["Is_Total_Valid"] = df["Total Spent"] == (df["Quantity"])*(df["Price Per Unit"])
```


```
food = ["Cake", "Cookie", "Salad", "Sandwich"]
drink = ["Coffee", "Juice", "Smoothie", "Tea"]
```

```
df["Category"] = df["Item"].apply(lambda x: "Food" if x in food else "Drink")
```

Hasil:


	Transaction ID	Item	Quantity	Price Per Unit	Total Spent	Payment Method	Location	Transaction Date	Month	Is_Total_Valid	Category
0	TXN_1961373	Coffee	2.0	2.0	4.0	Credit Card	Takeaway	2023-09-08	9	True	Drink
1	TXN_4977031	Cake	4.0	3.0	12.0	Cash	In-store	2023-05-16	5	True	Food
2	TXN_4271903	Cookie	4.0	1.0	4.0	Credit Card	In-store	2023-07-19	7	True	Food
3	TXN_7034554	Salad	2.0	5.0	10.0	Credit Card	Takeaway	2023-04-27	4	True	Food
4	TXN_3160411	Coffee	2.0	2.0	4.0	Digital Wallet	In-store	2023-06-11	6	True	Drink
...	...	...	...	...	...	...	...	...	...	...	...
9995	TXN_7672686	Coffee	2.0	2.0	4.0	Digital Wallet	Takeaway	2023-08-30	8	True	Drink
9996	TXN_9659401	Cookie	3.0	1.0	3.0	Digital Wallet	Takeaway	2023-06-02	6	True	Food
9997	TXN_5255387	Coffee	4.0	2.0	8.0	Digital Wallet	Takeaway	2023-03-02	3	True	Drink
9998	TXN_7695629	Cookie	3.0	1.0	3.0	Digital Wallet	In-store	2023-12-02	12	True	Food
9999	TXN_6170729	Sandwich	3.0	4.0	12.0	Cash	In-store	2023-11-07	11	True	Food
9514 rows × 11 columns											

PENEMUAN DARI FEATURE ENGINEERING



Penemuan:

- Tidak ada tren temporal dalam bulan tertentu
- Makanan dan minuman terjual dengan jumlah yang nyaris seimbang



MINMAX SCALING DAN ENCODING


```
scaler = MinMaxScaler()  
df["Quantity"] = scaler.fit_transform(df[["Quantity"]])  
df["Price Per Unit"] = scaler.fit_transform(df[["Price Per Unit"]])  
df["Total Spent"] = scaler.fit_transform(df[["Total Spent"]])
```

```
le = LabelEncoder()  
df["Item"] = le.fit_transform(df[["Item"]])  
df["Payment Method"] = le.fit_transform(df[["Payment Method"]])  
df["Location"] = le.fit_transform(df[["Location"]])
```

Hasil:

	Transaction ID	Item	Quantity	Price Per Unit	Total Spent	Payment Method	Location	Transaction Date	Month	Is_Total_Valid	Category
0	TXN_1961373	1	0.25	0.25	0.125000	1	1	2023-09-08	9	True	Drink
1	TXN_4977031	0	0.75	0.50	0.458333	0	0	2023-05-16	5	True	Food
2	TXN_4271903	2	0.75	0.00	0.125000	1	0	2023-07-19	7	True	Food
3	TXN_7034554	4	0.25	1.00	0.375000	1	1	2023-04-27	4	True	Food
4	TXN_3160411	1	0.25	0.25	0.125000	2	0	2023-06-11	6	True	Drink

FINAL DATASET



BEFORE

	Transaction ID	Item	Quantity	Price Per Unit	Total Spent	Payment Method	Location	Transaction Date
0	TXN_1961373	Coffee	2	2.0	4.0	Credit Card	Takeaway	2023-09-08
1	TXN_4977031	Cake	4	3.0	12.0	Cash	In-store	2023-05-16
2	TXN_4271903	Cookie	4	1.0	ERROR	Credit Card	In-store	2023-07-19
3	TXN_7034554	Salad	2	5.0	10.0	UNKNOWN	UNKNOWN	2023-04-27
4	TXN_3160411	Coffee	2	2.0	4.0	Digital Wallet	In-store	2023-06-11
...	...	...	...	...	...	...	...	...
9995	TXN_7672686	Coffee	2	2.0	4.0	NaN	UNKNOWN	2023-08-30
9996	TXN_9659401	NaN	3	NaN	3.0	Digital Wallet	NaN	2023-06-02
9997	TXN_5255387	Coffee	4	2.0	8.0	Digital Wallet	NaN	2023-03-02
9998	TXN_7695629	Cookie	3	NaN	3.0	Digital Wallet	NaN	2023-12-02
9999	TXN_6170729	Sandwich	3	4.0	12.0	Cash	In-store	2023-11-07

10000 rows × 8 columns

Data yang sudah bersih tidak mempunyai null value dan punya kolom tambahan untuk menganalisa tren bulanan dan penjualan

AFTER

	Transaction ID	Item	Quantity	Price Per Unit	Total Spent	Payment Method	Location	Transaction Date	Month	Is_Total_Valid	Category
0	TXN_1961373	1	0.25	0.25	0.125000	1	1	2023-09-08	9	True	Drink
1	TXN_4977031	0	0.75	0.50	0.458333	0	0	2023-05-16	5	True	Food
2	TXN_4271903	2	0.75	0.00	0.125000	1	0	2023-07-19	7	True	Food
3	TXN_7034554	4	0.25	1.00	0.375000	1	1	2023-04-27	4	True	Food
4	TXN_3160411	1	0.25	0.25	0.125000	2	0	2023-06-11	6	True	Drink
...	...	...	...	...	...	...	...	...	...	...	...
9995	TXN_7672686	1	0.25	0.25	0.125000	2	1	2023-08-30	8	True	Drink
9996	TXN_9659401	2	0.50	0.00	0.083333	2	1	2023-06-02	6	True	Food
9997	TXN_5255387	1	0.75	0.25	0.291667	2	1	2023-03-02	3	True	Drink
9998	TXN_7695629	2	0.50	0.00	0.083333	2	0	2023-12-02	12	True	Food
9999	TXN_6170729	5	0.50	0.75	0.458333	0	0	2023-11-07	11	True	Food

9514 rows × 11 columns

PERUBAHAN

```
Total data setelah preprocessing: 9514
Data yang hilang: 486
```

486 baris (0,0486% dari seluruh data) dihapus. Maka bisa disimpulkan, penghapusan data dengan jumlah yang kecil tidak merusak akurasi analisa lanjut.

	Transaction ID	Item	Quantity	Price Per Unit	Total Spent	Payment Method	Location	Transaction Date
0	TXN_3611851	NaN	4.0	NaN	NaN	Credit Card	NaN	2023-02-09
1	TXN_7524977	UNKNOWN	4.0	NaN	NaN	ERROR	NaN	2023-12-09
2	TXN_7376255	UNKNOWN	NaN	NaN	25.0	NaN	In-store	2023-05-27
3	TXN_9646000	ERROR	2.0	NaN	NaN	NaN	In-store	2023-12-14
4	TXN_1082717	ERROR	NaN	NaN	9.0	Digital Wallet	In-store	2023-12-13
...	...	...	...	...	...	...	...	...
481	TXN_9460419	Cake	1.0	3.0	3.0	Credit Card	Takeaway	NaT
482	TXN_8253472	Cake	1.0	3.0	3.0	Credit Card	In-store	NaT
483	TXN_3130865	Juice	3.0	3.0	9.0	Credit Card	In-store	NaT
484	TXN_9226047	Smoothie	3.0	4.0	12.0	Cash	In-store	NaT
485	TXN_9594133	Cake	5.0	3.0	15.0	Digital Wallet	Takeaway	NaT

486 rows × 8 columns

Ada 2 tipe dari baris yang dihapus:

1. Baris yang di antara 2-3-nya dari fitur item, quantity, price per unit, total spent bernilai null, unknown atau error. Baris ini tidak memberi insight penjualan
2. Baris yang tidak mempunyai nilai transaction date. Baris ini tidak memberi insight tren mingguan atau bulanan

KESIMPULAN

Dataset ini adalah dataset transaksi kafe yang relatif bersih dengan persentase 95,14% data berhasil dipertahankan setelah preprocessing.

Proses cleaning yang dilakukan:

- Baris dengan data transaksi inti yang tidak lengkap dan baris tanpa tanggal transaksi dihapus (486 baris)
- Nilai yang hilang diisi berdasarkan pola harga per item, kalkulasi matematis, dan imputasi probabilistik

Temuan dari Data Understanding:

- Distribusi item, payment method, dan lokasi relatif seimbang
- Tidak ada tren temporal yang signifikan per bulan


Limitasi:

- Imputasi probabilistik pada Item, Payment Method, dan Location adalah asumsi, bukan fakta





TERIMA KASIH



LINK CANVA:

HTTPS://CANVA.LINK/FB03PQ0Z
AVWCPE